


# ***Introdução à Inteligência Artificial e Computacional***

Leonardo Bonato Felix



## **Universidade Federal de Viçosa**

### **Reitor**

Demetrius David da Silva

### **Vice-Reitora**

Rejane Nascentes



Coordenadoria de  
Educação Aberta e a Distância

### **Diretor**

Francisco de Assis de Carvalho Pinto

*Campus Universitário, 36570-900, Viçosa/MG*

*Telefone: (31) 3612 1251*

**Layout:** Ana Luísa Medeiros e Stéfany Peron

**Editoração Eletrônica:** Ana Luísa Medeiros

**Edição de conteúdo e CopyDesk:** João Batista Mota



# Significado dos ícones da apostila

Para facilitar o seu estudo e a compreensão imediata do conteúdo apresentado, ao longo de todas as apostilas, você vai encontrar essas pequenas figuras ao lado do texto. Elas têm o objetivo de chamar a sua atenção para determinados trechos do conteúdo, com uma função específica, como apresentamos a seguir.



**DESTAQUE:** são definições, conceitos ou afirmações importantes às quais você deve estar atento.



**GLOSSÁRIO:** Informações pertinente ao texto, para situá-lo melhor sobre determinado termo, autor, entidade, fato ou época, que você pode desconhecer.


**SAIBA MAIS:** se você quiser complementar ou aprofundar o conteúdo apresentado na apostila, tem a opção de links na internet, onde pode obter vídeos, sites ou artigos relacionados ao tema.



**PARA REFLETIR:** vai fazer você relacionar um tópico a uma situação externa, em outro contexto



**Exercícios Propostos:** são momentos pra você colocar em prática o que foi aprendido



## ***Sumário***

<b>Currículo</b>	<b>7</b>
<b>Apresentação</b>	<b>8</b>
<b>1. Uma história do cérebro</b>	<b>9</b>
<b>2. O que é Inteligência Artificial e Computacional?</b>	<b>12</b>
<b>3. Tipos de aprendizado</b>	<b>16</b>
<b>4. Algumas aplicações</b>	<b>22</b>



# *Currículo*

## **Leonardo Bonato Felix**


Tem graduação (UFSJ, 2002), mestrado (UFMG, 2004) e doutorado (UFMG, 2006) também em Engenharia Elétrica. Foi pesquisador visitante da University of Southampton-UK (2019-2020).

É professor do Departamento de Engenharia Elétrica da UFV (2006-presente), atuando nas disciplinas de Inteligência Computacional, Sinais e Sistemas, Modelagem e Identificação de Sistemas, Introdução à Engenharia Biomédica, Eletrônica, etc.

É pesquisador 1D CNPq, atuando no processamento de sinais biológicos, teoria da detecção e aplicações de inteligência artificial.

Contato: leobonato@ufv.br.

Currículo vitae (Lattes): <http://lattes.cnpq.br/3019426714283734>



# *Apresentação*

Esta é a apostila da disciplina de *Introdução à Inteligência Artificial e computacional*. Nela, nós vamos falar primeiramente da principal fonte de inteligência que os seres humanos conhecem: o cérebro humano.

Assim, nesta primeira disciplina, nós teremos contato com uma pequena história do cérebro. Veremos também quais foram os caminhos que a ciência percorreu até que pudéssemos chegar a este ponto de entendimento do cérebro que nós temos hoje.

Boa leitura e bons estudos!



# 1. Uma história do cérebro

## 1. CONTEXTUALIZAÇÃO

Aqui, a motivação é falar da Inteligência Artificial e o que aconteceu com a ciência e com o cérebro, conforme a evolução científica foi se desenvolvendo. Não é de se esperar que o valor que nós damos hoje ao cérebro e, consequentemente, à inteligência seja assim desde o início da humanidade. Não. De fato, essa história é razoavelmente controversa e cheia de reviravoltas, tendo até contornos de drama (ou romance). Então, é interessante que resgatemos essa perspectiva histórica do cérebro e, consequentemente, da inteligência que emerge dele.



Os primeiros registros sobre o cérebro datam de épocas pré-históricas, entre 3000 e 1500 anos antes de Cristo. Naquele tempo, duas civilizações notáveis coabitavam a Terra, provavelmente sem terem entrado em contato uma com a outra: as civilizações pré-colombiana e egípcia.

No que diz respeito à civilização pré-colombiana, eles tinham uma forma muito peculiar de lidar com o cérebro. Junto a alguns sítios de escavação, foram encontrados evidências e restos de instrumentos usados para cirurgias na cabeça. Esses equipamentos são chamados de trepanadores e ainda são usados para se fazer perfurações médicas em crânios.

Todavia, essas civilizações davam um valor um pouco diferente do que nós damos hoje ao cérebro. Os indícios sugerem que quando alguém chegava a uma condição supostamente originada de maus espíritos (tais condições, geralmente, envolviam desmaios e convulsões), eles consideravam que a cabeça dessa pessoa estava tomada pelo mau espírito e era preciso “aliviá-la”. Assim, eles faziam um buraco para permitir que o espírito, que estava gerando convulsões, pudesse sair daquele corpo.

Apesar de essas civilizações pré-colombianas não terem dado ao cérebro o protagonismo nesse tipo de situação, eles ainda faziam uma coisa certa. Isso porque, ao fazerem essa manobra, eles promoviam um alívio na pressão do crânio e a pessoa poderia efetivamente ter a sobrevivência aumentada. Assim, embora não tratassem ainda efetivamente do que era o cérebro, eles já tinham uma noção da relação do cérebro com o controle do corpo. Mesmo que, de uma forma muito intuitiva, eles já estavam no caminho correto.

Outra civilização, o povo do Egito antigo, dava uma importância diferente ao cérebro. Um fato interessante diz respeito ao hieróglifo encontrado no famoso papiro médico de Edwin Smith (de possível autoria de Imhotep e que descrevia vários casos médicos): ali se encontrava a primeira inscrição do termo “cérebro”.

Além dessa menção, os egípcios antigos não davam tanta importância ao cérebro em si. Por exemplo, o processo de mumificação dava muito mais valor às vísceras - como o coração, fígado, etc. - do que ao cérebro. Normalmente, essas vísceras tinham suas próprias jarras para serem acondicionados ao lado do corpo. Já o cérebro não tinha nenhuma serventia: ele era simplesmente sugado pelo nariz para esvaziar o crânio e evitar a putrefação.

Após um razoável salto no tempo, vale a pena a gente estudar a história do cérebro e da inteligência por meio de dois expoentes da antiguidade: Aristóteles (384-322 a.c) e Galeno (130-200 d.c.).



Aristóteles, dentre várias outras coisas, se preocupou em tentar entender como os seres humanos desenvolviam e mantinham a capacidade de raciocínio e inventividade. Provavelmente, a partir de seus estudos de dissecação, ele concluiu que o que nos fazia diferentes e onde estava toda nossa potência intelectual e raciocínio era o coração.



Ele acreditava que todos os seres vivos eram feitos da mesma matéria bruta e a vida que os percorria vinha através do *anima*, de um sopro divino. Esse *anima* compunha um fluido animal que percorreria todo o nosso corpo por tubos específicos. Em relação ao cérebro humano, Aristóteles acreditava que a sua função era esfriar nosso fluido animal nos tornando racionais. Assim, o cérebro poderia ser visto como um “radiador” para o órgão principal, que era o coração.

No auge do Império Romano, um médico que ficou muito conhecido foi Cláudio Galeno. Dentre outras coisas contribuições, rejeitou as ideias de Aristóteles em relação ao papel do cérebro. Ele não deu ao cérebro o papel secundário de “radiador do fluido animal”. Para o médico, se o cérebro fosse feito para resfriar o fluido animal proveniente do coração, ele teria sido feito em torno do coração, e não longe dele.

Esta conclusão partia da premissa de que, como isso não parecia certo, não poderia ser divino. Com isso, ele propôs que as faculdades mentais e a base do raciocínio humano vinham dos ventrículos cerebrais - cavidades preenchidas por fluido que ficavam dentro do cérebro. A partir de Galeno, o cérebro foi colocado no lugar mais correto, como centro das sensações e do raciocínio.

Com a queda do Império Romano e a ascensão da Igreja Católica, aconteceu a proibição de estudos de dissecação humana. Assim, acabou-se com a principal fonte de informação para os estudos do cérebro naquela época. Isso levou a cerca de 1300 anos de estagnação, em termos de informação nova relacionada ao cérebro.

Somente por volta de 1500 d.C. surgiu o trabalho *De humanis corporis fabrica*, de autoria de Andreas Vesalius (atualmente considerado o pai da anatomia). Ali, ele acabou contestando Galeno sobre quais seriam as funções dos ventrículos que existiam no cérebro. Além disso, propôs o nervo como forma de transmissão do movimento e de sensações a partir do cérebro.

Em 1649, já sob a égide do Iluminismo, Descartes publicou seu último trabalho: *Les passions de l'âme*. Ele propôs uma teoria chamada de dicotomia mente-cérebro. Segundo Descartes, existia o mundo material, no qual os nossos corpos e os dos animais estavam imersos e compartilhavam o mundo espiritual - o outro plano de existência, que seria o mundo onde habitava a mente.

Nessa dicotomia, o corpo físico tinha uma função muito automatizada e controlada pelo cérebro – semelhante a um autômato movido por força hidráulica. Assim, necessidades de luta, fuga, fome e as consequentes reações eram inerentes a todos os seres vivos, e o cérebro apenas ajustava o movimento do corpo em função da necessidade.

O que nos diferenciava dos outros animais é que nós, além de sistema de gerenciamento da máquina do corpo (cérebro), tínhamos também uma fonte de informação que vinha do mundo espiritual que a nossa mente habitava. Nossas memórias e inteligência seriam acessadas em função de nossas necessidades, por meio de uma espécie de antena – a glândula pineal. Provavelmente ela foi escolhida por estar mais ou menos no centro geométrico do cérebro. Outras culturas descrevem essa pequena parte do cérebro como o terceiro olho, etc.

A partir das discussões promovidas pós-iluminismo, já não se tinha dúvida de que o cérebro era o centro da inteligência. Os estudos subsequentes verificaram e explicaram muito do que viria a se tornar a neurociência.





Estudar a inteligência e, conseqüentemente, a inteligência artificial é um problema complexo, porque, considerando que os neurônios são a base dos nossos comportamentos inteligentes, nós temos, em média, 100 bilhões de neurônios por pessoa. Para se ter uma ideia de comparação, é mais ou menos o número de estrelas que se tem na Via Láctea. Além disso, em termos de organização, dentro de um milímetro cúbico de córtex tem-se em torno de 800 milhões de sinapses e 4 km de axônios. Em outras palavras, tem-se no córtex 4 km de cabos compactados dentro de um milímetro cúbico de matéria. E isso não é pouca coisa!

Comparativamente com outras espécies, por exemplo, o elefante e o golfinho têm cérebros maiores que os nossos. A nossa vantagem está na razão entre o volume do cérebro e o volume corporal. Nesse caso, nossa relação é a maior. Então, essa informação revela que a maior capacidade cognitiva provavelmente não se relaciona com o tamanho do cérebro, mas sim com suas interconexões e capacidade de armazenar/resgatar memórias.



## 2. O que é Inteligência Artificial e Computacional?

Vamos falar sobre o que é Inteligência Artificial (IA) e Computacional e também discutir os conceitos relacionados a essa disciplina. A Inteligência Computacional pode ser entendida como uma área da ciência da computação, mas ela acaba pegando inspiração e conceitos de várias outras áreas, como a filosofia, psicologia, biologia, etc. Em outras palavras, a IA pode ser considerada multidisciplinar.



A Inteligência Computacional entra para resolver problemas nos quais a computação tradicional não foi capaz de gerar soluções tão boas no mundo real. Pode-se dizer que de 80% a 90% das soluções necessárias para as coisas do dia a dia são alcançadas com computação tradicional. Para os outros 10% ou 20% de casos, para os quais nós não temos uma solução tão boa oferecida pela computação algorítmica tradicional, podemos usar técnicas de Inteligência Artificial e Computacional.

Nos últimos anos, a importância da Inteligência Artificial ficou muito maior dada à grande evolução das capacidades de armazenamento de informações e da velocidade de transmissão dessas informações na internet. Atualmente, tem-se volumes de dados sendo armazenados e que contêm informações muito importantes sobre coisas que são de interesse de algumas pessoas.

Por exemplo, o comportamento de compra e venda de cada pessoa na internet. A análise de um número de dados tão extensa é muito difícil para computação tradicional. Uma das formas mais bem-sucedidas de analisar grandes volumes de dados é a partir de programas de computador que emulem, em certos aspectos, a inteligência biológica.

Esses programas podem ser escritos para aprender padrões em um volume muito grande de informações. Uma vez ajustados, podem oferecer respostas para problemas pelos quais não foram programados inicialmente. Essa é uma das motivações para se criar programas inteligentes, o qual tem por custo uma maior demanda de poder computacional.



Enfim, como responder a seguinte pergunta: O que é Inteligência Artificial?



Não existe ainda uma única definição e a expressão *inteligência artificial* geralmente está relacionada à habilidade que um computador tem de aprender uma tarefa específica a partir de dados ou observações. De forma geral, o objetivo da IA é entender os princípios que tornam possíveis comportamentos inteligentes. Assim, a partir desse objetivo geral, criam-se como objetivo específico sistemas inteligentes que sejam úteis para determinadas aplicações.

Os métodos de IA são sempre baseados em comportamentos inteligentes sejam eles de onde forem. Em outras palavras, isso quer dizer que eles são inspirados em outras áreas nas quais existe

algum comportamento que pode ser considerado inteligente (ou automático) funcionando.

Antes de fazer a pergunta “O que é Inteligência Artificial?”, é importante que a gente se pergunte antes: O que é inteligência?

Uma busca em um dicionário pode levar à seguinte definição: “Faculdade de conhecer, compreender, aprender e de adaptar-se a novas situações”. Essa é uma possível definição de inteligência. No nosso caso, talvez seja melhor definir o que seja um agente inteligente, pois esse pode ser tanto artificial ou biológico.

Assim, um agente inteligente tem que:

- a) agir apropriadamente em função de objetivos;
- b) se adaptar quando os objetivos mudarem;
- c) aprender com as experiências;
- d) fornecer respostas razoáveis mesmo em face de informações limitadas ou incompletas.

Quando se tem a necessidade de medir o quanto inteligente é um ser humano, você pode fazer um teste de quociente de inteligência (QI). Para o caso de um sistema de IA, o matemático e cientista Alan Turing criou um teste que recebeu o seu nome. Nesse teste, é preciso fazer um ser humano, dito A, interagir de forma cega com a IA em teste e com um ser humano B. Se ao final da interação o ser humano A não puder diferenciar quem é a máquina, diz-se que o sistema passou no teste de Turing.

O teste de Turing pode ser aplicado para diferentes tarefas e em diferentes durações. Quanto mais tarefas e tempo forem usados no teste, mais completa seria a IA que passar no teste.

## 1. ALGUNS PARADIGMAS DE IA

Os métodos de IA podem ser divididos de acordo com seu paradigma de inspiração e classificados conforme o balanço dos níveis de dados e de conhecimento teórico necessários para a sua implementação. Como exemplo de paradigma tem-se o simbolista, que é inspirado na capacidade humana de manipulação de símbolos e requer um grande conhecimento teórico antes da sua implementação, porém poucos dados. Outro exemplo são os algoritmos evolutivos, inspirados na seleção natural, que necessitam de baixos níveis tanto de conhecimento teórico, quanto de dados do problemas a ser resolvido.

### 1.1. Paradigma simbolista

Vamos começar falando do paradigma simbolista, de uma forma informativa. O simbolismo considera que o comportamento inteligente segue um algoritmo. Em outras palavras, as tarefas que os seres inteligentes desempenham, como classificação de padrões, são uma sequência de passos lógicos. Ou seja, este paradigma reduz o grande problema a ser resolvido em pequenos problemas que devem ser resolvidos de forma sequencial. A combinação dessas soluções parciais gera a solução do problema maior.



Esse tipo de pensamento reducionista deu origem aos chamados sistemas especialistas, nos quais o sistema computacional (usando linguagens como o *lisp* ou *prolog*) deve armazenar informações como se fossem parte de uma árvore. Assim, uma vez adicionada a informação em um galho, esse galho se subdividiria em outros com novas informações mais detalhadas, relacionadas ao galho que lhes deu origem. Com a árvore montada, o processo de retirada de informações e, conseqüentemente, de solução de problemas, é alcançado por buscas nessa árvore. Tal abordagem tem por vantagem a possibilidade agregar conhecimentos de várias fontes em um único sistema de IA, que é chamado de sistema especialista.

## 1.2.Paradigma evolucionista

Esta abordagem é inspirada na teoria de evolução, proposta por Charles Darwin.

A evolução segue algumas premissas:

- 1) a diversidade é gerada por cruzamento não-aleatório e mutações;
- 2) os indivíduos mais adaptados têm maior probabilidade de sobreviver;
- 3) as características genéticas dos pais são herdadas pelos filhos.

Em 1975, John Holland propôs um método de resolução de problemas de forma automática baseado na evolução e foi chamado de *algoritmo genético*. Nesse método, as possíveis soluções de um problema são consideradas indivíduos de uma geração, e as partes que compõem cada possível solução são considerados os genes. Assim, após ter gerado aleatoriamente um primeiro conjunto de indivíduos candidatos a solução, eles passaram por uma seleção por meio de alguma métrica avaliativa.



Os indivíduos (soluções) mais bem avaliados são usados para construir uma nova geração de soluções, que carrega genes de indivíduos da geração anterior em diferentes proporções. A nova geração passa por uma nova rodada de seleção e o processo continua, até que uma solução atinja o nível de qualidade desejado ou o número máximo de gerações seja alcançado.

Esse processo pode ser considerado tanto de otimização quanto de inteligência computacional. Nesse último caso, pelo fato de padrões ótimos emergirem automaticamente de dados gerados aleatoriamente.

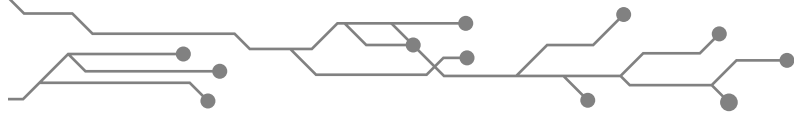
## 1.3.Paradigma conexionista

As ferramentas de IA que fazem parte do paradigma conexionista são ferramentas matemáticas inspiradas nas conexões do sistema nervoso e no neurônio. O sistema nervoso pode ser considerado em três partes: sistema nervoso central, periférico e medula espinhal. Todos os sistemas nervosos são formados por uma célula em comum: o neurônio. Ele tem um corpo celular onde estão localizados o núcleo com o material genético e as organelas citoplasmáticas. O neurônio conta com uma membrana encapsuladora chamada membrana plasmática; algumas protuberâncias nessa membrana são chamadas de dendritos. Os dendritos são responsáveis pela recepção de informações vinda de outros neurônios. Cada neurônio tem, via de regra, uma projeção de membrana mais pronunciada, chamada de axônio, a qual é usada para transmitir informação do neurônio para os outros.

Os neurônios apresentam vários formatos, dependendo de qual parte do corpo eles estão. No córtex cerebral, os neurônios do tipo piramidal são abundantes e estão associados à nossa capacidade cognitiva. Eles estão conectados entre si numa forma de rede. Os neurônios de camadas mais profundas do córtex se conectam, preferencialmente, com outros de camadas subsequentes.

O neurônio é uma célula excitável, no sentido elétrico. Isso significa que o neurônio é uma célula que tem um comportamento diferente quando ela recebe algum tipo de informação elétrica. A eletricidade usada pelos neurônios para a sua comunicação é gerada pelo fluxo de íons pela membrana plasmática. O fluxo é consequência das diferentes concentrações desses íons dentro e fora da célula. A membrana plasmática é permeável a certos íons específicos – através de canais iônicos - e essa corrente de íons gerada em resposta ao gradiente químico é chamada de bioeletricidade.

Quando acontece uma alteração elétrica suficientemente alta em parte da membrana, alguns canais iônicos se ativam e permitem influxos e efluxos de íons em quantidade muito superior às condições de repouso. A troca rápida de íons percorre toda a membrana até chegar ao fim do axônio, onde a informação elétrica é transduzida em informação química na sinapse. É na



sinapse que os neurotransmissores químicos saem do neurônio onde aconteceu o evento elétrico – chamado de potencial de ação – e atingem o dendrito do neurônio seguinte. Assim, se essa sinapse for muito forte ou muito síncrona com outras semelhantes, o neurônio seguinte pode entrar em modo de potencial de ação, propagando a informação.



Essa dinâmica de ação do neurônio inspirou a criação de um modelo matemático não-linear por McCulloch e Pitts, em 1943. Nesse modelo, as sinapses advindas de outros neurônios foram consideradas as entradas do modelo. Tais entradas eram ponderadas (i.e., multiplicadas) por constantes que representavam as sinapses – sendo que essas constantes poderiam ser qualquer número real.

O corpo celular é modelado como um somatório dessas entradas ponderadas e cuja saída é comparada com um valor limite – que representa o potencial de membrana que deflagra o potencial de ação. Assim, se o valor do somatório for maior que o limiar, a saída do modelo é colocada em modo ativo; ou seja, 1 (um). Caso contrário, a saída do modelo é zero. Nesse modelo original, as entradas e saídas foram definidas como binárias. A esse modelo matemático inspirado no neurônio biológico deu-se o nome de neurônio artificial. Já quando se associam vários desses neurônios em cascata dá-se o nome de rede neural artificial.

Com o passar do tempo, várias melhorias foram inseridas nas redes neurais artificiais, tais como: algoritmos eficientes de treinamento, métodos para lidar com sobreparametrizações, etc. Mais recentemente, com a facilitação de acesso a computadores de alto desempenho – através da computação nas nuvens e do uso de placas gráficas –, um avanço no paradigma conexionista foi alcançado pelas redes de aprendizado profundo (*deep learning*). Essas redes usam várias camadas de processamento de dados para extração de informação automática (chamadas de redes convolucionais) e, subsequentemente, apresentam essas informações a uma rede neural artificial para posterior aprendizado de máquina.



## 3. Tipos de aprendizado

Uma situação corriqueira em IA é que usamos dados para ajustar um modelo para aprender a lógica de uma decisão complexa. Geralmente, a decisão é tão complexa que o próprio programador não conhece a lógica correta; não sabe como traduzir essa lógica em um formato amigável ao computador, ou ambos. Se a lógica fosse simples e conhecida pelo programador, ele poderia simplesmente programá-la diretamente.

Aprender a lógica de uma decisão complexa normalmente é realizado por meio do uso de um conjunto de dados. Dependendo do tipo de dados que recebemos, há duas maneiras diferentes de aprender essa lógica de decisão.

### 1. APRENDIZAGEM SUPERVISIONADA

Nessa aprendizagem, temos um conjunto de dados de treinamento que são rotulados. Dados rotulados significam que a resposta “certa” nos é fornecida. Em termos mais técnicos, sabemos a saída esperada para aquele conjunto de entradas específico. Ter rótulos é importante por dois motivos: primeiro, fornecemos entradas ao modelo matemático treinado e geramos saídas (previsões). Como temos rótulos, podemos comparar as previsões de nossa lógica com as saídas esperadas (rótulos) e ver o quanto nossas previsões estão precisas.

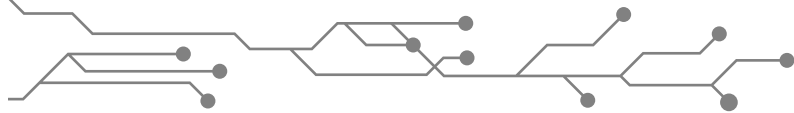


A qualidade dos dados de treinamento é importante, porque presumimos que eles refletem os acontecimentos do mundo real nos quais queremos usar nosso sistema de IA. Uma boa precisão nos dados de treinamento geralmente se traduz em uma boa precisão no mundo real também. Se os dados de treinamento não são muito fidedignos ao mundo real, é essencialmente impossível gerar boas previsões. Isso geralmente é descrito pela frase: “entra lixo, sai lixo”.

Se descobirmos que nosso sistema de IA não está produzindo boas previsões, podemos usar os rótulos para seu segundo propósito: guiar o aprimoramento do nosso treinamento. Na verdade, é precisamente daí que vem o termo “supervisionado”: algoritmos que têm um elemento de aluno, que é o modelo a ser treinado. Eles também têm um elemento de professor que supervisiona o aluno e usa os rótulos (ou saídas desejadas) para fornecer retorno sobre as previsões.

Vejamos um exemplo. Suponha que você queira ser capaz de prever o consumo de combustível dos carros com precisão, como você poderia fazer isso? Uma coisa que você poderia fazer facilmente é apontar para carros na estrada e dizer: “Acho que esse gasta X Km/L.” Sem qualquer tipo de *feedback*, no entanto, é bastante improvável que isso melhore suas suposições. Você não só não saberia se seus palpites estavam próximos ou não, como também não saberia como eles estavam errados; eles estavam muito altos ou muito baixos?

Sem *feedback*, o processo para, mas podemos reiniciá-lo reunindo mais dados. Suponha, então, que você foi a uma feira de automóveis onde havia centenas de carros com etiquetas na vitrine listando, entre outras coisas, o consumo de combustível. Agora você pode olhar para um carro, fazer uma previsão e, em seguida, comparar essa previsão com o consumo real listado na janela. Suponha que, a princípio, você tenha previsto que os carros esportivos fazem 12 Km/L e os SUVs a 8 Km/L. A verificação de dois ou três exemplos rotulados diferentes seria o suficiente para fazer você perceber que as suposições eram fora da realidade e que, na verdade, os SUVs têm um consumo de combustível menor do que os carros esportivos (em geral).



Quanto mais retorno você obtém, mais você reconheceria tendências: carros com velocidade final maior com pior consumo de combustível; motores maiores com menor consumo de combustível, e carros mais novos, tendo melhor consumo de combustível do que os veículos mais antigos.

No longo prazo, todos esses padrões se traduzem em melhores previsões gerais. Não apenas isso; eles fornecem uma boa ideia do tipo de erros que você pode esperar ao prever novas situações. Se o seu erro médio nas previsões for 5 Km/L, quando você fizer uma nova previsão, você deve ter certeza de que ela estará próxima do valor verdadeiro. Se seu erro médio for 20 Km/L, talvez não seja possível fazer previsões precisas com os dados disponíveis. Em ambos os casos, a supervisão nos dá informações cruciais sobre nosso modelo preditivo.

## 2. APRENDIZAGEM NÃO SUPERVISIONADA

Aqui, basicamente, “não-supervisionado” se torna um termo geral para qualquer coisa que não siga o padrão professor-aluno e não tenha nenhum elemento de supervisão. Pela maioria das definições, o aprendizado não-supervisionado é um tipo de aprendizado de máquina. No aprendizado supervisionado, estamos procurando padrões nos dados para que possamos conectar esses padrões aos rótulos de uma forma que, esperançosamente, nos permita prever os rótulos com precisão.



Na aprendizagem não-supervisionada, ainda procura-se padrões, mas não se tem rótulos para associar esses padrões. Portanto, as abordagens não supervisionadas tendem a procurar tipos específicos de padrões com base na suposição de que esses padrões geralmente são importantes.

Encontrar agrupamentos de pontos semelhantes, por exemplo, normalmente significa que esses pontos têm algo em comum, mesmo que não saibamos exatamente o que é.

Encontrar pontos que são muito diferentes do resto dos dados normalmente significa que existem características nesses pontos que são únicas em comparação com o resto. Sem uma investigação mais aprofundada, geralmente não saberemos o que é essa característica exclusiva, mas identificar pontos discrepantes é a primeira etapa necessária nesse processo.

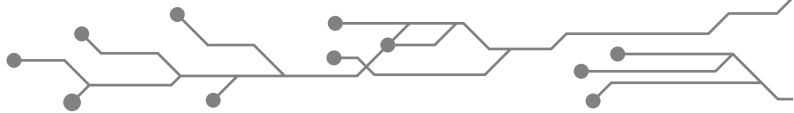
### 2.1.Descrevendo o conjunto de dados

Dada a importância dos dados para o aprendizado de máquina, ter uma forma eficiente para descrever os dados acaba sendo essencial. Na grande maioria, o conjunto de dados pode ser considerado uma planilha ou tabela. As colunas são chamadas de características ou variáveis. Cada linha é um exemplo ou observação. Os exemplos também são comumente chamados de pontos de dados ou apenas pontos, porque matematicamente eles representam um ponto em um espaço  $n$ -dimensional, onde  $n$  é o número de características.



No aprendizado supervisionado, as características que usamos para prever a saída são chamadas de variáveis de entrada, preditores ou variáveis independentes. A saída desejada é chamada de variável de saída ou variável dependente. Elas geralmente são emparelhadas: se você vir o termo “variáveis independentes” para as entradas, você esperaria que “variável dependente” fosse usada para a saída. Nos códigos e nas equações, as variáveis de entrada são geralmente referidas como  $X$ , enquanto as variáveis de saída (ou rótulos) usam  $Y$ .





Por que tantos termos para as mesmas coisas? A teoria por trás do aprendizado de máquina é usada e desenvolvida em vários campos. Os economistas geralmente usam “variáveis independentes / dependentes”; os estatísticos geralmente usam “preditores / respostas”; e os cientistas da computação são mais propensos a usar “entradas / saídas”.

- **Sinal e ruído**

Todos os dados contêm informações, mas essas informações são divididas em duas partes: sinal e ruído. **Sinal** é o que queremos; é a parte valiosa e útil dos dados. O **ruído** pode vir de muitas fontes, mas o efeito é sempre introduzir variações nos dados que não queríamos e não podemos interpretar.

**Exemplificando, para entender melhor...**

Vamos considerar um exemplo: trabalhamos para uma secretaria de educação e ouvimos sobre um estudo em que adicionar mais plantas à escola tenha melhorado as pontuações dos testes. Queremos tentar isso, mas por motivos de orçamento, a secretaria não quer plantas reais. Ela só quer comprar um monte de plantas falsas, na esperança de que o efeito seja o mesmo. Eles decidiram tentar isso em apenas uma escola, antes de implementar o projeto em toda a região.

Para a surpresa de muitos, os resultados dos testes desta escola sobem muito depois de adicionar as plantas de plástico. Naturalmente, os responsáveis estão entusiasmados, mas será que alguma outra coisa está acontecendo aqui?

Na verdade, sim. Mais ou menos um mês antes de as plantas serem adicionadas, a escola fez parceria com uma faculdade local para receber estudantes universitários e fornecer aulas particulares com os alunos do ensino médio. Nossa análise não considerou ou controlou isso - não fazia parte do conjunto de dados -, mas faz sentido que o programa de tutoria provavelmente teve mais a ver com o aumento do teste do que as plantas falsas.

Agora, vamos considerar isso por meio da relação sinal/ruído. Nesse caso, “sinal” são quaisquer informações exclusivas sobre os efeitos das plantas falsas. Queremos apenas medir o efeito das plantas nas pontuações dos testes. No entanto, o ruído surgiu na forma de coisas que não medimos e que ainda afetaram o resultado - especificamente o programa de tutoria.

Variáveis não medidas são uma fonte extremamente comum de ruído, mas existem outras. Uma fonte comum de ruído quando os dados vêm de sensores é a interferência eletromagnética. A interferência é uma das primeiras formas de ruído a ser amplamente estudada (por companhias telefônicas) e, como gera um zumbido estático e constante quando ouvida por um alto-falante, também é a origem do termo “ruído” quando usado neste sentido.

Como lidamos com o ruído? Na maioria das vezes, nós não lidamos, pois é apenas uma parte inerente de nossos conjuntos de dados. Às vezes, é possível remover a contribuição do ruído: adicionando novas entradas (isto é, medindo as quantidades não medidas); controlando as variáveis ausentes e/ ou por meio de técnicas de remoção de ruído mais avançadas. A maior parte dessa remoção depende do tipo de ruído e de sua origem. Normalmente, eles não podem remover o ruído completamente.

Felizmente, os algoritmos de IA lidam razoavelmente com o ruído e gerarão os melhores modelos possíveis com os dados disponíveis. Às vezes, no entanto, os dados que recebemos simplesmente não podem gerar um modelo verdadeiramente eficaz. O ruído costuma ser o principal culpado quando isso acontece.



### 3. APRENDIZAGEM SUPERVISIONADA

Na aprendizagem supervisionada, o objetivo é aprender o mapeamento (ou as regras, o modelo, a função de transferência) entre um conjunto de entradas e saídas. Por exemplo, as entradas podem ser a previsão do tempo em uma semana e a saída o número de visitantes da praia. O objetivo do aprendizado supervisionado, nesse caso, seria aprender o mapeamento que descreve a relação entre a temperatura prevista e o número de visitantes da praia, baseando-se em exemplos de valores passados dessas variáveis.



Esses pares de entrada e saída são usados durante o processo de aprendizagem para ensinar o modelo como ele deve se comportar, portanto, realizando um aprendizado “supervisionado”. Para o exemplo da praia, novas entradas podem ser alimentadas com a temperatura prevista e o algoritmo de IA produzirá uma previsão para o número de visitantes.

Ser capaz de se adaptar a entradas inéditas e fazer previsões é a parte crucial da generalização do aprendizado. Se o modelo for treinado em excesso, causaremos um ajuste excessivo aos exemplos usados e ele será incapaz de se adaptar a novas entradas não vistas anteriormente; ou seja, não generalizará bem.

Um problema a ser levado em conta na aprendizagem supervisionada que a supervisão pode introduzir é a tendência à aprendizagem. É possível que o modelo ajustado possa estar imitando exatamente o que foi mostrado no treinamento. Por isso, é muito importante mostrar exemplos confiáveis, balanceados e imparciais. Além disso, o aprendizado supervisionado geralmente requererá muitos dados antes de aprender.

A saída de um sistema de IA supervisionado pode ser uma categoria de um conjunto finito, por exemplo [baixo, médio, alto], para o número de visitantes na praia:



Quando este for o caso, ou seja, desejar-se tipificar ou classificar a entrada, isso é conhecido como classificação.

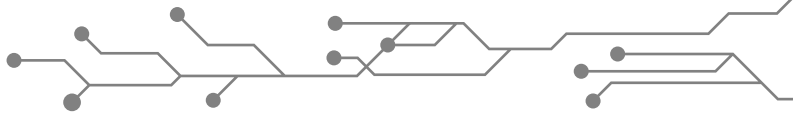
Como alternativa, a saída poderia ser um escalar:



Esse último procedimento é conhecido como regressão

#### 3.1. Classificação

A classificação é usada para agrupar os pontos semelhantes em diferentes seções para



classificá-los. O aprendizado de máquina é utilizado para encontrar as regras que explicam como separar os diferentes pontos de dados.

Mas como as regras são criadas? Bem, existem várias maneiras de descobrir as regras. Todas elas se concentram no uso de dados para descobrir regras que separam linearmente os pontos de dados.

- **Separabilidade linear**

A separabilidade linear é um conceito-chave em IA. A separabilidade linear significa: os diferentes pontos de dados podem ser separados por uma reta. De forma simples, este tipo de abordagem de classificação tenta encontrar a melhor maneira de separar os pontos de dados com uma reta.

- **Superfície de decisão**

As linhas traçadas entre as classes são conhecidas como limiar de decisão. Toda a área usada para definir uma classe é conhecida como superfície de decisão. A superfície de decisão define que se um ponto cair dentro de seus limites, ele será atribuído a esta classe.

### 3.2. Regressão

A regressão é outra forma de aprendizagem supervisionada. A diferença entre classificação e regressão é que esta última produz um número em vez de uma classe na saída. Portanto, a regressão é útil ao prever problemas baseados em números, como: preços do mercado de ações, temperatura para determinado dia ou a probabilidade de um evento.

### 3.3. Exemplos

A regressão é usada no comércio financeiro para encontrar os padrões em ações e outros ativos para decidir quando comprar/vender e obter lucro. A definição se um *e-mail* que você recebe é *spam* é uma forma de classificação.



As técnicas de aprendizagem supervisionada de classificação e regressão podem ser estendidas a tarefas muito mais complexas. Por exemplo, tarefas que envolvem fala e áudio. Classificação de imagens, detecção de objetos e *bots* de bate-papo são alguns exemplos.

Um exemplo recente, mostrado no *link*, usa um modelo treinado com aprendizagem supervisionada para vídeos de pessoas falando realisticamente. Disponível em: [https://www.youtube.com/watch?v=FlgLxSLsYWQ&feature=emb\\_rel\\_pause](https://www.youtube.com/watch?v=FlgLxSLsYWQ&feature=emb_rel_pause)

## 4. APRENDIZADO NÃO-SUPERVISIONADO

No aprendizado não-supervisionado, apenas dados de entrada são fornecidos para o treinamento. Não há saídas rotuladas a serem associadas. Mas pode ser surpreendente saber que ainda é possível encontrar muitos padrões interessantes e complexos ocultos nos dados sem quaisquer rótulos.

Um exemplo de aprendizagem não-supervisionada na vida real seria classificar moedas de cores diferentes em pilhas separadas. Ninguém lhe ensinou como separá-las, mas apenas olhando suas características, como a cor, você pode ver quais moedas estão associadas e agrupá-las em seus grupos corretos.



O aprendizado não-supervisionado pode ser mais difícil do que o aprendizado supervisionado, pois a remoção da supervisão significa que o problema se tornou menos definido. O algoritmo tem uma ideia menos focada de quais padrões procurar. Pense nisso em seu próprio aprendizado. Se você aprendeu a tocar violão sendo supervisionado por um professor, aprenderá rapidamente reutilizando o conhecimento supervisionado de notas, acordes e ritmos. Mas se você só estudasse sozinho, seria muito mais difícil saber por onde começar.

No aprendizagem não-supervisionada, você começa do zero e pode até encontrar uma maneira nova e melhor de resolver um problema. Por isso, também é conhecida como descoberta de conhecimento. Ela é muito útil ao conduzir análises exploratórias de dados.

Para encontrar as estruturas interessantes em dados não rotulados, a forma mais comum é o agrupamento. Entre outros, há também a redução de dimensionalidade, modelos de variáveis latentes e detecção de anomalias. Técnicas não-supervisionadas mais complexas envolvem redes neurais como Autocodificadores e *Deep Belief Networks*.

#### 4.1. Clustering

O aprendizado não-supervisionado é usado principalmente para agrupamento ou *clustering*, que é o ato de criar grupos com características diferentes. O clustering tenta encontrar vários subgrupos em um conjunto de dados.

Como esse é um aprendizado não-supervisionado, não estamos restritos a nenhum conjunto de rótulos e somos livres para escolher quantos *clusters* criar. Isso, porém, é tanto benção, quanto maldição. A escolha de um modelo com o número correto de *clusters* deve ser conduzida por meio de um processo empírico de seleção de modelo.


#### 4.2. Redução de dimensionalidade

A redução de dimensionalidade visa encontrar as características mais importantes para reduzir o conjunto de características originais em um subconjunto menor e mais eficiente que ainda representa os dados.



Por exemplo, ao prever o número de visitantes da praia, podemos usar a temperatura, o dia da semana, o mês e o número de eventos programados para esse dia como entradas. Mas o mês pode não ser importante para prever o número de visitantes.

Características irrelevantes como essa podem confundir os algoritmos de IA e torná-los menos eficientes e precisos. Usando a redução de dimensionalidade, apenas os recursos mais importantes são identificados e usados. A Análise de Componentes Principais (PCA) é uma técnica comumente usada para isso.



## 4. Algumas aplicações

A demanda crescente por profissionais que dominam técnicas de programação de IA deve tornar este tipo de emprego muito concorrido ao longo do século. Além disso, IA é um tema muito frequente para filmes, livros, pesquisadores e todas as mídias. Toda grande empresa planeja investir nisso.

Observe, a seguir, alguns projetos que já utilizam IA no mundo real. Como fonte de referência futura, *links* para bancos de dados e para projetos de implementação serão fornecidas sempre que possível.

### 1. CLASSIFICAÇÃO DE MÚSICAS EM DIFERENTES GÊNEROS

Vamos supor um cenário no qual, por algum motivo, encontramos um monte de arquivos MP3 com nomes aleatórios em nosso disco rígido, que supostamente contém música. Nossa tarefa é classificá-los de acordo com o gênero musical em pastas diferentes, como jazz, clássica, country, pop, rock e metal. O objetivo, então, é ajustar uma IA para classificar as músicas em diferentes gêneros.

- **Implementações no mundo real:**

- usado em plataformas de *streaming*, como *Spotify*, *Gaana*, etc.

- **Fontes de projeto:**

- **Music Genre Classification** (<https://data-flair.training/blogs/python-project-music-genre-classification/>): é um projeto que usa aprendizado profundo para classificar automaticamente diferentes gêneros musicais a partir de arquivos de áudio.

- **Bancos de dados:**

- **FMA - A Dataset For Music Analysis** (<https://github.com/mdeff/fma>): um banco de dados aberto e acessível, adequado para avaliar várias tarefas de MIR (Music Information Retrieval), que é um campo relacionado com a navegação, pesquisa e organização de grandes coleções de música.

### 2. SISTEMA DE RECONHECIMENTO FACIAL

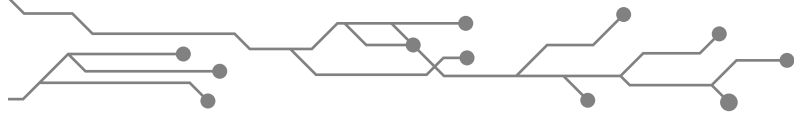
Os sistemas de reconhecimento facial são capazes não apenas de reconhecer o rosto de uma pessoa, mas também podem prever o seu gênero, idade, humor e estado de saúde. Os sistemas de reconhecimento facial são usados em muitas empresas em diferentes setores, como pagamentos, anúncios, segurança, mídia social, etc., dependendo dos requisitos da empresa.

- **Implementações no mundo real:**

- O *Facebook* e outras plataformas de mídia social identificam automaticamente as pessoas nas imagens, usando seus sistemas de reconhecimento facial.
  - A *MasterCard* tem um aplicativo de pagamento chamado *MasterCard Identity Check*.

- **Fontes de projeto:**

- **Real-Time Face Recognition - An End-To-End Project** (<https://towardsdatascience.com/real-time-face-recognition-an-end-to-end-project-b738bb0f7348>): é um projeto que descreve o passo a passo para implementar um sistema de reconhecimento de rostos em *hardware* dedicado.



- **Face recognition with OpenCV, Python, and deep learning** (<https://www.pyimagesearch.com/2018/06/18/face-recognition-with-opencv-python-and-deep-learning/>).

- **Bancos de dados:**

- **10 Face Datasets To Start Facial Recognition Projects** (<https://analyticsindiamag.com/10-face-datasets-to-start-facial-recognition-projects/>): repositório de *links* para vários bancos de dados contendo imagens de rostos.

- **60 Facial Recognition Databases** (<https://www.kairos.com/blog/60-facial-recognition-databases>).

### 3. DETECÇÃO DE SPAM E IDENTIFICAÇÃO DE DISCURSO DE ÓDIO

Os sistemas de detecção de *spam* e de identificação de discurso de ódio detectam texto indesejado, não solicitado e de discurso de ódio. São usados em várias plataformas de mídia social, artigos, *e-mails*, mensagens encaminhadas, etc.

- **Implementação no mundo real:**

- Filtragem de *spam* usada pelo G-Mail.
- Detecção de discurso de ódio nas redes sociais, como youtube, twitter, Facebook.

- **Fontes de projeto:**

- **Machine Learning Hatespeech Detection** (<https://github.com/PaulRostecki/hatespeech-detection-project>): é um projeto que tem por objetivo analisar e detectar discurso de ódio em polônês.

- **E-mail Spam Filtering** (<https://www.kdnuggets.com/2017/03/email-spam-filtering-an-implementation-with-python-and-scikit-learn.html>): implementação de dois classificadores de spam usando python.

- **Bancos de dados:**

- **Hatespeechdata** (<https://hatespeechdata.com>): é uma página que administra um catalogo de vários bancos de dados de discurso de ódio e linguagem ofensiva - inclusive em português.
- **Enron-Spam datasets** (<http://www2.aueb.gr/users/ion/data/enron-spam/>): contém os bancos de dados de *spam* usados no artigo *Spam Filtering with Naive Bayes – which Naive Bayes?*

### 4. PREDIÇÃO DE TAGS

No mundo das mídias sociais, todo artigo, vídeo, imagem, etc. tem *tags* associadas a ele. Uma *tag* é uma espécie de etiqueta digital usada nas redes sociais para agrupar e identificar determinado tipo de material.

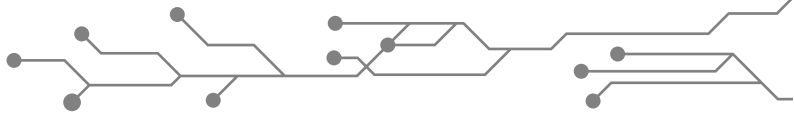
- **Implementação no mundo real:**

- *Tags* usadas em mídias sociais como Twitter, Facebook, Instagram, youtube, etc.

- **Fontes de projeto:**

- **Auto Tagging Stack Overflow Questions** (<https://towardsdatascience.com/auto-tagging-stack-overflow-questions-5426af692904>): é um projeto de classificação de texto para predição de *tags* para o famoso *site* de compartilhamento de informações de desenvolvedores, *Stack Overflow* (é bem provável que você use esse *site* algum dia).

- **Bancos de dados:**



- **Facebook Recruiting III - Keyword Extraction** (<https://www.kaggle.com/c/facebook-recruiting-iii-keyword-extraction/data>): esse banco de dados foi usado pelo *Facebook* para seleção de vagas de emprego na empresa. O candidato deveria mostrar suas habilidades na predição de *tags* para o *Facebook*.

## 5. SISTEMAS DE RECOMENDAÇÃO

Um sistema de recomendação é um sistema de filtragem de informações que busca prever a preferência de um usuário para determinado item. Eles são usados em várias empresas de Internet para recomendar seus usuários.

- **Implementações no mundo real:**
  - Sistema de recomendação na plataforma de mídia social, como TikTok, Facebook, Youtube.
  - Sistema de recomendação em plataformas do tipo *over the top* (OTT), como Netflix, Disney+.
  - Sistema de recomendação em um *site* de comércio eletrônico, como Amazon, Walmart.
- **Fontes de projeto:**
  - **The Top 99 Recommender System Open Source Projects** (<https://awesomeopensource.com/projects/recommender-system>): um vasto repositório de projetos de sistemas de recomendação dos mais variados tipos.
- **Bancos de dados:**
  - **Netflix Prize data** (<https://www.kaggle.com/netflix-inc/netflix-prize-data>): a Netflix ofereceu um prêmio de US\$1.000.000 (isso mesmo: 1 milhão de dólares!) para uma competição aberta pelo melhor algoritmo de recomendação usando por base esse banco de dados.

## 6. CHATBOTS

Um *chatbot* é um aplicativo usado para conduzir uma conversa *on-line* via texto ou conversão de texto em voz, em vez de fornecer contato direto com um agente humano ao vivo.

- **Implementações no mundo real:**
  - São largamente usados por bancos.
  - Alguns *sites* de reserva de ingressos para eventos / shows.
  - O aplicativo *Whatsapp* tem suporte para implementação de *chatbots*, geralmente usados por empresas.
- **Projetos:**
  - **Build Your First Python Chatbot Project** (<https://dzone.com/articles/python-chatbot-project-build-your-first-python-pro>): um tutorial para criar um *chatbot* do zero usando python.
  - **The Top 43 Chatbots Open Source Projects** (<https://awesomeopensource.com/projects/chatbots>): Repositório de projetos *open source* de criação de *chatbots* variados.
- **Banco de dados:**
  - **15 Best Chatbot Datasets for Machine Learning** (<https://lionbridge.ai/datasets/15-best-chatbot-datasets-for-machine-learning/>): repositório de bancos de dados com perguntas e respostas realistas para treinamento de *chatbots*.



## 7. RECONHECIMENTO DE ATIVIDADES HUMANAS

O reconhecimento da atividade humana é uma tarefa que envolve prever o movimento de uma pessoa com base nos dados de sensores, como um acelerômetro, câmera ou giroscópio.

- **Implementações no mundo real:**

- Usado para fins de vigilância usando *drones* ou câmeras de CCTV.
- Usado em telemedicina para rastrear o estado de saúde da pessoa.
- Usado na indústria de jogos.

- **Projetos:**

**Deep Learning Models for Human Activity Recognition** (<https://machinelearningmastery.com/deep-learning-models-for-human-activity-recognition/>): projeto desenvolvido em *python* para predição de atividade humana baseado nos registros de acelerômetro de celular.

- **Banco de dados:**

**Human activity recognition** (<https://data.world/uci/human-activity-recognition>): Registros de 30 sujeitos realizando atividades cotidianas usando *smartphones* com sensores.

## 8. RECONHECIMENTO DE CARACTERES MANUSCRITOS

O reconhecimento de texto escrito à mão, uma categoria de Reconhecimento Ótico de Caracteres (do inglês *Optical Character Recognition*, OCR), é a capacidade de um computador de receber e interpretar entradas manuscritas inteligíveis e converter em texto.

- **Implementação no mundo real:**

- OCR para entrada de dados.
- OCR usado em *gadgets*.
- Validação de assinaturas.

- **Projetos:**

- **Offline Handwriting Recognition CNN** (<https://www.kaggle.com/tejasreddy/offline-handwriting-recognition-cnn>): é um *notebook* da plataforma Kaggle com a implementação de modelos matemáticos para a classificação de usuários baseados no estilo da caligrafia.

- **The Top 19 Optical Character Recognition Open Source Projects** (<https://awesomeopensource.com/projects/optical-character-recognition>): repositório de projetos.

- **Bancos de dados:**

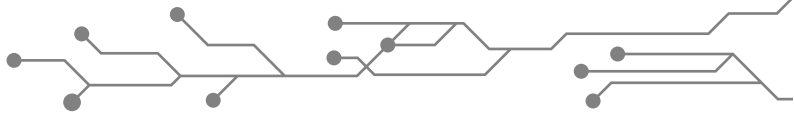
- **Best OCR & Handwriting Datasets for Machine Learning** (<https://lionbridge.ai/datasets/15-best-ocr-handwriting-datasets/>): lista de algumas de dezenas de bancos de dados contendo manuscritos digitalizados.

## 9. PREVISÃO DE PREÇO

A estimativa de tarifas lucrativas é uma importante tática de negócios usada por vários *sites* de *e-commerce* e reserva de passagens. Um modelo de IA ajuda essas empresas a estimar um preço. Os sistemas de previsão de preços também são usados em várias empresas de comércio de ações para prever os preços futuros das ações.

- **Implementação no mundo real:**

- Previsão de preços de produtos para vários sites de comércio eletrônico, como Amazon,



Walmart, etc.

- Previsão do preço das ações.
- Previsão de tarifas de passagens para voos, hotéis, táxis, usados por Airbnb, uber, etc.

- **Projetos:**

- **Stock Price Prediction** (<https://data-flair.training/blogs/stock-price-prediction-machine-learning-project-in-python/>): projeto com códigos de aprendizado de máquina para previsão do preço de ações.

- **Banco de dados:**

- **House Price Prediction** (<https://www.kaggle.com/c/neolen-house-price-prediction>): banco de dados de preço de vendas de casas no EUA. Faz parte de uma competição do kaggle com o objetivo de treinamento.

## 10. GERADOR AUTOMÁTICO DE LEGENDA

Os computadores ainda estão muito atrás dos humanos em compreender o contexto ao ver uma imagem. Porém, um gerador baseado em IA pode gerar automaticamente legendas para uma imagem. A legendagem de imagens faz parte do Processamento de Linguagem Natural (do inglês *natural language processing*, NLP).

- **Implementação no mundo real:**

- O Google usa legendagem automática de imagens nos seus resultados de pesquisa de imagens.
  - *Sites* de galeria de imagens, como o Google Photos, podem entender as imagens carregadas usando sistemas de legendagem de imagens.

- **Projetos:**

- **Learn to Build Image Caption Generator** (<https://data-flair.training/blogs/python-based-project-image-caption-generator-cnn/>): códigos para a implementação de um sistema de geração automática de legendas usando *deep learning*.

- **Banco de dados:**

- **Flicker30k** (<https://forms.illinois.edu/sec/229675>): banco de dados de mais de 30 mil imagens e suas respectivas legendas. Disponível após requisição e registro.







Coordenadoria de  
Educação Aberta e a Distância